Uma Revisão Expandida de Extreme Learning Machine

João Victor Moreira Cardoso, Marcos Heitor Carvalho de Oliveira,
Matheus Viana Coelho Albuquerque, Rodrigo Beltrão Valença

***Abstract*—A máquina de aprendizado extremo (ELM) é um algoritmo de treinamento para redes neurais de camada única oculta (SLFN), que converge mais rápido que os métodos tradicionais e o ajuste dos seus parâmetros tem resultado em desempenhos promissores. Este artigo oferece uma revisão abrangente da ELM, abordando a análise teórica, melhorias em estabilidade, eficiência e precisão quando comparado com outros algoritmos de machine learning como a Máquina de Vetores de Suporte (SVM). Também discutimos o uso de ELM em aplicações recentes nas mais diversas áreas do conhecimento. Nosso objetivo é demonstrar a comparação do algoritmo e explorar perspectivas futuras.**

***Index Terms*—Feedforwards Neural Network, Deep Learning, Extreme Learning Machine, Models Comparisons, Support Vector Machine, Real-Time Learning**

I. Introdução

ESTE trabalho discute e complementa o trabalho de Wang *et al.* [1] sobre a eficiência do Extreme Learning Machine (ELM). Esse algoritmo foi proposto originalmente por Guang-Bin Huang, Qin-Yu Zhu e Chee-Kheong Siew, em 2006 [2] para treinar redes feedforward de camada única oculta (SLFNs). Diferente dos métodos baseados em gradiente, a ELM atribui valores aleatórios aos pesos entre a camada de entrada e a camada oculta, e aos vieses na camada oculta, que são mantidos fixos durante o treinamento. As funções de ativação não lineares na camada oculta fornecem não linearidade ao sistema. O único parâmetro a ser aprendido é o peso entre a camada oculta e a camada de saída. Assim, a ELM converge muito mais rápido do que os algoritmos tradicionais, pois aprende sem iteração. Além disso, os nós ocultos aleatórios garantem a capacidade de aproximação universal [2]. A ELM oferece melhor generalização sem ajustar iterativamente os parâmetros ocultos. A teoria da ELM foi comprovada por Guang-Bin e Qin-Yu [2].

Devido à sua superioridade em velocidade de treinamento, precisão e generalização [3], a Máquina de Aprendizado Extremo foi utilizada em diversos campos de aplicação, como medicina, química, transporte, economia, robótica, entre outros [1,4,5,6]. Embora o trabalho de Wang *et al.* tenha exposto diversos pontos de atuação do ELM em vários campos de estudo da computação, ainda há novos trabalhos que estão sendo feitos e que devem ser discutidos.

II. Objetivo

Apresentar o atual estado da arte do tema e tentar acrescentar novas perspectivas recentes sobre o Extreme Machine Learning (ELM), i.e., trazer algumas aplicações mais recentes e novas variações do ELM proposto por Huang *et al.* [2], de forma que busquemos atualizar o trabalho realizado por Wang *et al.* [1]. Para tal, faremos comparações entre o ELM original, outros modelos de ELM (seção III) e modelos já bem conhecidos e discutidos de Aprendizado e Máquina como, por exemplo Random Forest, SVM, RNN, KNN, entre outros.

III. Revisão de Literatura

Essa seção apresenta nossa contribuição com o estudo realizado por Wang *et al.* [1] sobre estado da arte em 2024 sobre as extensões e comparações do ELM original proposto por Huang *et al.* [2].

Como apresentado em [1], o ELM tem diversas aplicações na área de classificação. Por exemplo, o trabalho mais recente de G.B. Huang *et. al.*, [7] aborda sobre o uso do ELM como uma ferramenta unificada e eficiente para regressão e classificação multiclasse, superando as limitações e a complexidade computacional das técnicas convencionais de *Least Squares Support Vector Machine* (LS-SVM) e *Proximal Support Vector Machine* (PSVM). A ELM se destaca por não exigir ajustes na camada oculta das redes e proporcionar resultados rápidos e eficazes, podendo aproximar qualquer função contínua e classificar regiões disjuntas com melhor desempenho e escalabilidade. Comparada às abordagens tradicionais, a ELM oferece soluções de aprendizado com menor complexidade de otimização e melhor desempenho de generalização, especialmente em classificação multiclasse.

Também comparando-o com as abordagens tradicionais de SVM com o ELM, em "Optimization method based extreme learning machine for classification" [6], G. B. Huang *el al.* apresentam como a ELM pode integrar aspectos do SVM para a separação de hiperplanos, simplificando o processo de aprendizado e aumentando a sua eficiência. Análises teóricas e empíricas do artigo mostram novamente que as ELMs alcançam melhor desempenho de generalização e são menos sensíveis aos parâmetros especificados pelo usuário.

A comparação entre ELM e SVM para esses problemas de classificação tem atraído a atenção de vários pesquisadores. O trabalho de S. O. Olatunji [5], por exemplo, investiga como SVM e ELM se comparam no problema

da detecção de spam em emails. Resultados empíricos mostraram que ambas as técnicas superaram as melhores técnicas publicadas anteriormente no mesmo conjunto de dados popular utilizado neste estudo. No entanto, a SVM teve um desempenho melhor do que a ELM em termos de precisão, mas em termos de velocidade de operação, a ELM superou significativamente a SVM.

Ainda no campo da classificação, mas voltado para um contexto médico, o ELM tem sido usado para auxiliar na detecção do câncer. O artigo de S. Keskin *et al.* [3] compara o desempenho das Máquinas de Aprendizado Extremo com outros métodos de aprendizado de máquina no conjunto de dados de Diagnóstico de Câncer de Mama de Wisconsin. O estudo demonstra que a abordagem ELM supera outras técnicas, como Perceptron de Múltiplas Camadas, Otimização Sequencial Mínima, Aprendizado de Árvore de Decisão, Naive Bayes e K-Nearest Neighbor na classificação deste conjunto de dados. Outro trabalho que usa o ELM para a detecção do câncer é o trabalho de S. Al-Hammouri *et al.* [8]. Neste trabalho, os autores se propõem a detectar o Melanoma, o tipo de câncer de pele que apresenta desafios significativos na detecção precoce. O estudo foca na eficácia do classificador Máquina de Aprendizado Extremo (ELM), obtendo uma taxa de precisão de 97% na classificação de imagens de melanoma. A introdução do ELM neste domínio trouxe benefícios de velocidade, simplicidade e precisão ao processo de classificação. Além desses estudos, o paper de V. V. Vardhan Reddy *el al.* [9] também mostra como o modelo aprimorado da Máquina de Aprendizado Extremo com Kernel (KELM) pode ser usada para detecção de tumores cerebrais. Nesse trabalho, o modelo KELM obteve uma precisão de 93,31%, demonstrando ser uma ferramenta mais eficaz para o diagnóstico médico preciso de tumores cerebrais. A metodologia proposta pode ajudar a melhorar a detecção precoce de tumores cerebrais, o que é crucial para aumentar as chances de tratamento eficaz e sobrevivência dos pacientes.

Outras abordagens também modificam o comportamento padrão do ELM a fim de adequar o algoritmo para o cenário de estudo proposto. M. Zhou e W. Ai [10] apresenta uma abordagem em ambiente distribuído com uma técnica para distribuir o treinamento de Máquinas de Aprendizado Extremo com Kernel Reduzido (RKELM) usando o método de Multiplicadores de Direção Alternada (ADMM). A técnica, chamada DRKELM, melhora a eficiência computacional e o tempo de processamento sem comprometer a precisão. Experimentos mostram que o método distribuído é mais eficiente do que a abordagem centralizada, tornando-o adequado para grandes conjuntos de dados. Y. Liu *et al.*, por sua vez, trabalham com o ELM em um ambiente online. No artigo, Y. Liu e os outros autores propõem e comparam um novo algoritmo de Máquina de Aprendizado Extremo Sequencial Online em Conjunto (EOS-ELM-R) para a previsão da qualidade do ar [11]. A Máquina de Aprendizado Extremo Sequencial Online (OS-ELM) é um algoritmo eficaz para cenários de aprendizado online, mas enfrenta problemas devido à atribuição aleatória de alguns parâmetros, o que leva à instabilidade no desempenho do modelo. Os resultados dos experimentos com os dados de qualidade do ar de Pequim (PM 2.5) e Oslo (PM 10) demonstraram que o EOS-ELM-R possui um melhor desempenho em termos de erro quadrático médio (RMSE) em comparação com o OS-ELM e EOS-ELM, tanto no conjunto de treinamento quanto no de teste.

Além do contexto médico, algumas aplicações usam o ELM no campo da geografia e da engenharia. O trabalho de A. Bardhan *et al.* [12] propõe a integração de técnicas de inteligência de enxame neuro-adaptativas (ANSI) com máquinas ELM para determinar a razão de suporte da Califórnia (CBR) de solos para camadas de subleito de trilhos ferroviários, um problema crítico da engenharia geotécnica em tempo real. A otimização por enxame de partículas (PSO) com coeficientes de aceleração adaptativos e variáveis no tempo (TAC) foi empregada para otimizar os parâmetros de aprendizado do ELM. Três novos modelos ANSI baseados em ELM, nomeadamente ELM acoplado com PSO modificado (ELM-MPSO) foram desenvolvidos para prever o CBR de solos em condições encharcadas. Comparado ao PSO padrão (SPSO), as versões modificadas e aprimoradas do PSO são capazes de convergir para uma solução de alta qualidade nas primeiras iterações. A comparação foi feita entre os modelos propostos e outras técnicas convencionais de computação suave, como ELM convencional, Rede Neural Artificial, Programação Genética e Máquina de Vetor de Suporte. Os resultados experimentais revelaram que os modelos ANSI baseados em ELM podem alcançar a previsão mais precisa e confirmam a dominância do MPSO sobre o SPSO. Considerando as consequências e robustez dos modelos propostos, concluiu-se que os novos modelos ANSI baseados em ELM, especialmente o ELM-MPSO, podem resolver as dificuldades em ajustar os coeficientes de aceleração do SPSO pelo método de tentativa e erro para prever o CBR de solos e serem aplicados a outros problemas em tempo real da engenharia geotécnica.

O algoritmo do ELM também já foi combinado com outras técnicas de aprendizagem para solucionar o problema de classificação partindo de uma abordagem de *clusters*. X. Tang e L. Chen [13] propuseram um método baseado em uma combinação da Máquina de Aprendizado Extremo Ponderada (WELM) e o Algoritmo de Otimização de Colônia de Abelhas (ABC), chamado HABC-WELM. Esse método tenta ser uma abordagem eficiente para o problema de conjuntos de dados desbalanceados, comuns em aplicações do mundo real, que afetam o desempenho de classificação de muitos métodos de aprendizado. A eficácia do método HABC-WELM foi validada em 15 conjuntos de dados desbalanceados. Comparado a vários métodos, incluindo SVM ponderado, métodos de *ensemble* e outros métodos baseados em WELM, o HABC-WELM demonstrou desempenho superior. O estudo concluiu que o HABC-WELM oferece uma solução robusta para problemas de dados desbalanceados, superando a maioria dos métodos comparativos. O método não apenas melhora a

classificação das classes minoritárias, mas também garante uma melhor generalização do modelo.

Contribuições mais recentes mostram que o algoritmo do ELM ainda permanece como tópico de interesse de vários pesquisadores. Em N. Kardani *et al.* e A. Bardhan *et al.* [14,15], o grupo de pesquisadores se inspiram no movimento de animais para acoplar novas técnicas ao algoritmo original do ELM. Em [14] é proposto um algoritmo de otimização Harris Hawks (HHO) aprimorado, acoplado com uma ELM para resolver problemas de regressão. O HHO é inspirado na estratégia de caça das águias Harris e é utilizado para otimizar os parâmetros da ELM. O artigo destaca que a combinação do HHO com a ELM melhora significativamente a precisão e a eficiência da predição em comparação com outras técnicas tradicionais de aprendizado de máquina. Os experimentos realizados demonstraram que o modelo híbrido (HHO-ELM) supera outros modelos em várias métricas de desempenho, indicando seu potencial como uma ferramenta robusta para problemas de regressão complexos. Enquanto isso, em [15] os autores apresentam uma técnica inovadora baseada no algoritmo de vaga-lumes melhorado (IFF), também acoplado com uma ELM, para prever a condutividade térmica do solo. O estudo propõe a hibridização do algoritmo de vaga-lumes com técnicas de aprendizado de máquina (ELM, ANFIS, ANN) para melhorar a precisão das previsões. Entre os modelos híbridos testados, o ELM-IFF mostrou o melhor desempenho preditivo, com alta precisão e baixa margem de erro.

Além das novas técnicas, estudos gerais do estado da arte do ELM continuam em produção. H. Patil e K. Sharma, por exemplo, oferecem uma pesquisa recente e abrangente sobre as ELM, cobrindo suas teorias, algoritmos e aplicações [16]. O estudo explora várias melhorias e variações do ELM, incluindo métodos de otimização e técnicas híbridas que aumentam sua precisão e eficiência. As aplicações do ELM são vastas, abrangendo desde a previsão financeira até a biomedicina. O artigo mostra que, apesar de suas vantagens, ainda existem desafios e oportunidades para pesquisas futuras no aprimoramento dos algoritmos ELM e na expansão de suas aplicações.

IV. Compreensão do Artigo

Nessa seção será apresentada a revisão esquemática do artigo "A Review On Extreme Learning Machine" dos autores Jian Wang, Siyuan Lu, Shui-Hua Wang e Yu-Dong Zhang [1], cada seção representa um resumo geral e crítico do conteúdo abordado no artigo original.

A. Fundamentação Teórica

Nesta parte, apresentamos a análise teórica da ELM básica. A ELM foi inventada para treinar SLFNs, a estrutura de rede neural artificial mais amplamente usada. Uma SLFN convencional consiste em três camadas: camada de entrada, camada oculta e camada de saída. x e o denotam os vetores de entrada e saída. w e b representam o peso da entrada para a camada oculta e o viés da camada oculta. β denota o peso da saída. Treinar a rede é determinar esses parâmetros para alcançar a solução ótima.

1) Treinamento de SLFN: Nesta seção, introduzimos brevemente o problema de treinamento para SLFN. Dado um conjunto de treinamento $S = \{(x_i, t_i)|x_i = (x_{i1}, x_{i2}, \ldots, x_{in})^T \in \mathbb{R}^n, t_i = (t_{i1}, t_{i2}, \ldots, t_{im})^T \in \mathbb{R}^m\}$, onde x_i denota o valor de entrada e t_i representa o alvo, a saída o de uma ELM com N_b neurônios ocultos pode ser expressa como:

$$\sum_{i=1}^{N_b} \beta_i g(w_i x_j + b_i) = o_j, \quad j = 1, \ldots, N$$

onde $g(x)$ é a função de ativação na camada oculta. Na ELM, as funções de ativação são não lineares para proporcionar mapeamento não linear para o sistema. O objetivo do treinamento é minimizar o erro entre o alvo e a saída da ELM. A função de custo mais comumente usada é o erro quadrático médio (MSE):

$$\text{MSE} = \sum_{i=1}^{N} (t_{ij} - o_{ij})^2, \quad j = 1, \ldots, m$$

onde N é o número de amostras de treinamento. Pode-se provar que a SLFN é capaz de aproximar todas as amostras de treinamento quando o número de nós ocultos N tende ao infinito,

$$\sum_{j=1}^{N} \|o_j - t_j\| = 0$$

o que é chamado de capacidade de aproximação universal. Portanto, deve existir um conjunto de w_i, b_i e β_i que satisfaçam:

$$\sum_{i=1}^{N_b} \beta_i g(w_i x_j + b_i) = t_j, \quad j = 1, \ldots, m$$

A fórmula acima pode ser abreviada como:

$$H\beta = T$$

onde

$$H(w_1, \ldots, w_{N_b}, b_1, \ldots, b_{N_b}, x_1, \ldots, x_N) =$$

$$\begin{pmatrix} g(w_1 x_1 + b_1) & \cdots & g(w_{N_b} x_1 + b_{N_b}) \\ \vdots & \ddots & \vdots \\ g(w_1 x_N + b_1) & \cdots & g(w_{N_b} x_N + b_{N_b}) \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_1^T \\ \vdots \\ \beta_{N_b}^T \end{pmatrix}, \quad T = \begin{pmatrix} t_1^T \\ \vdots \\ t_N^T \end{pmatrix}$$

Portanto, treinar a SLFN é encontrar os melhores w_i, b_i e β_i. Na figura 1 é possível observar a estrutura geral do SLFN.

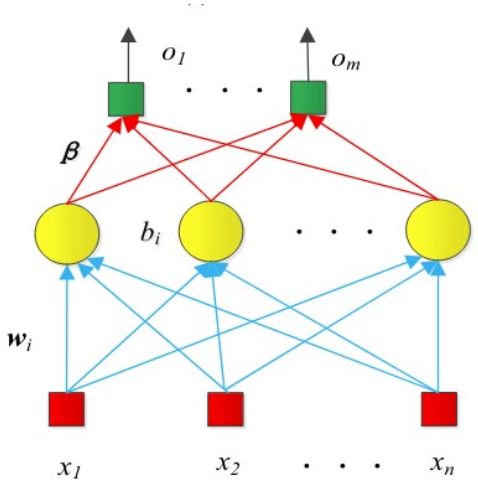


Fig. 1: Estrutura de uma *SLFN*

2) Princípios do ELM: O treinamento básico da ELM pode ser resumido em dois passos: inicialização aleatória e solução linear de parâmetros. Primeiramente, a ELM usa parâmetros aleatórios w_i e b_i na camada oculta, que são mantidos fixos durante todo o processo de treinamento. O vetor de entrada é mapeado em um espaço de características aleatórias com funções de ativação não lineares, proporcionando capacidade de aproximação universal. Em seguida, β_i pode ser obtido pela inversa de Moore-Penrose, resolvendo $H\beta = T$. Assim, a ELM pode alcançar uma melhor generalização sem ajustar iterativamente os parâmetros ocultos.

A teoria da ELM foi rigorosamente comprovada por Guang-Bin e Qin-Yu, com informações detalhadas disponíveis na literatura. A ELM pode aproximar fronteiras de classificação complexas com um número suficiente de nós ocultos.

B. Variantes do ELM

Esta seção apresenta as variantes avançadas recentes da ELM. Vários algoritmos têm sido usados para melhorar o desempenho da ELM em aplicações reais.

1) Melhoria na Robustez: Para melhorar a robustez e estabilidade da ELM, várias abordagens foram propostas buscando calcular os pesos de saída β_i e reduzir a performance da classificação.

A ELM incremental (I-ELM) é proposta com a alteração dos nós ocultos serem adicionados gradualmente [17], mantendo a capacidade de aproximação universal. Já Xu e Yao [18] introduziram a ELM incremental regularizada (IR-ELM), que atualiza recursivamente o peso de saída.

Liu e Wang [19] sugeriram que a ELM pode sofrer de overfitting, então propuseram a ELM em conjunto (EN-ELM) com validação cruzada e votação majoritária para melhorar a generalização. Soria-Olivas e Gomez-Sanchis [20] combinaram ELM com uma abordagem Bayesiana, melhorando a eficiência em tarefas de regressão.

Wang e Cao [21] propuseram a ELM eficaz (EELM) selecionando pesos de entrada e vieses para evitar a matriz H singular, acelerando a computação da matriz inversa generalizada. Cao e Lin [22] usaram um algoritmo de evolução diferencial auto-adaptativo para treinar parâmetros dos nós ocultos, melhorando a classificação.

Liu e Wang [23] apresentaram a ELM com múltiplos kernels (MK-ELM), otimizando tanto os pesos da combinação de kernels quanto os pesos da rede, alcançando resultados comparáveis ao estado da arte com menor tempo de treinamento. Deng e Zheng [24] propuseram a ELM com kernel reduzido para diminuir o tempo de consumo sem afetar o desempenho, aplicando com sucesso em tarefas de reconhecimento de atividade entre pessoas.

2) Otimização de Parâmetros: Para tarefas que englobam um domínio mais específico, a performance da ELM pode ser melhorada através da otimização dos parâmetros de entrada. Chen e Lv [25] desenvolveram a RELM-IRLS para reduzir o impacto de outliers. Pesquisadores sugeriram otimizações de enxame para pesos e vieses, como o algoritmo dos vaga-lumes de Zhang e Li [26], M-ELM de Zhang e Wu [27], IWOA de Nayak e Dash [28], e GWO de Wang e Chen [29]. Zhang e Wu [30] introduziram a IC-ELM para evitar overfitting em pequenos conjuntos de dados. Zheng e Wang [31] usaram a ELM multicamada com NALO para detecção de falhas, enquanto Gao e Liu [32] propuseram a S-ELM para lidar com dados faltantes.

3) Modificação de Estrutura: Pesquisadores têm modificado a estrutura da ELM para melhorar seu desempenho. Bai e Kasun [33] criaram a ELM-LRF com campos receptivos locais para reconhecimento de objetos, superando DBN e CNN em precisão e tempo de treinamento. Deng e Bai [34] integraram SVD para análise de grandes dados, aumentando a eficiência computacional. Ouyang e Cheng [35] combinaram SVD e ELM com teoria fuzzy, melhorando os resultados em aprendizado online. Geng e Dong [36] introduziram a SOELM com aprendizado Hebbiano e ajuste auto-organizável da rede, obtendo bons resultados em processos químicos. Wu e Qu [37] desenvolveram uma ELM multicamada com otimização híbrida de nós ocultos, aprimorando a estrutura da rede.

4) ELM para Aprendizado Online: Para lidar com dados que crescem continuamente, Huang e Liang [38] propuseram a ELM sequencial online (OS-ELM), que ajusta parâmetros sequencialmente, evitando re-treinar sobre amostras antigas. Zhao e Wang [39] adicionaram um mecanismo de esquecimento para melhorar a validade temporal dos dados. Huynh e Won [40] usaram regularização de Tikhonov para reduzir o erro empírico. Mirza e Lin [41] propuseram a ELM sequencial online ponderada para tratar o desbalanceamento de classes, alcançando melhor desempenho em comparação com outros métodos.

5) ELM para Dados Desbalanceados: Como já sabemos, datasets desbalanceados são um problema para os modelos de Machine Learning e, também, de Deep Learning. Assim, o ELM, num dataset com classes muito maiores que outras - que é o que usualmente acontece nos "datasets do mundo real" *(sic)* -, termina por treinar mal classes minoritárias. Assim, Zong and Huang [42] propuseram o "Weighted

ELM" (W-ELM) para esse tipo de base de dados. A sugestão deles foi associar, à cada amostra de treino, pesos de acordo com a distribuição de classes. A formulação foi tal que:

$$\min_{\beta} \frac{1}{2}||\beta||^2 + \frac{1}{2}\sum_{i=1}^{N} C_i||\mathbf{e_i}||^2,$$
$$s.t.\ \mathbf{t_i^T} - \mathbf{e_i^T} = h(\mathbf{x_i})\beta,\ i = 1, 2, ...N$$

onde $\mathbf{e_i}$ é o erro da amostra x_i, C_i é o hiperparâmetro de peso de penalidade. Na prática, os pesos das classes majoritárias são usualmente configurados de forma menor quando comparados com os pesos das classes minoritárias. Um dos mais usados tipos de esquema de associação de peso é

$$w_i = \frac{1}{n(c_i)}$$

onde c_i é o rótulo da classe e $n(c_i)$ é o número de amostras pertencentes à classe. Ademais, o W-ELM performa bem com dados desbalanceados ou ainda com dados balanceados, alcançando uma boa generalização em ambos, e seu esquema pode ser aplicado em tarefas de "cost sensor learning". Posteriormente, Tang e Chen [13] implementaram uma otimização de uma colônia artificial de abelhas para treinar o W-ELM no que culminou na posterior melhora da sua performance de classificação. Shen e Zhang [4] propuseram o esquema deles para classificação binária desbalanceada. Eles usaram as classes minoritárias para treinar um "ELM Auto Encoder" (ELM-AE) para, assim, predizer mais amostras a essas classes. Com essas amostras geradas, fazemos a adição dessas novas amostras frutos do ELM-AE ao dataset, com a premissa de que essa ação balanceie o dataset.

6) ELM para Big Data: Temos que ter cautela ao implementar ELM com big data de modo a ser eficaz e realizável. Com isso, podemos fazer como Liu e Huang [43] usaram ELM para reduzir (por regressão espectral) a dimensão de dados com muitas dimensões. Com isso, podemos obter os pesos. O ELM proposto de duas etapas pode convergir mais rapidamente para dados com muitas dimensões. Já Xin e Wang [44] descobriram que o ELM era ineficiente no "MapReduce" para aprendizados atualizados de grandes dados. Com isso, eles propuseram o ELM Elástico, em que melhoram a eficiência da multiplicação de matrizes calculando gradualmente (a multiplicação de matrizes no ELM é a parte que mais consome tempo no aprendizado de grandes dados). Este modelo usa uma matriz intermediária de multiplicações do subconjunto de treino atualizado e obtém o peso de saída pelo cálculo centralizado. Com vários experimentos realizados para avaliação, o ELM Elástico mostrou-se rápido e efetivo para aprendizado de "big data". Ademais, Yang e Xu [45] aplicaram ELM para classificação de "Stream Data" e, logo, propuseram um ensemble de ELM. Embutindo um conceito de módulo de detecção de deriva no ELM, o modelo pôde agora reconhecer derivas graduais e abruptas por aprendizado sequencial online e atualização de classificadores. Por fim, Chen e Song [46] desenvolveram um algoritmo de adaptação de domínio baseados em ELM. A justificativa é baseada no conceito de que, muitas vezes, os dados de treino e teste são de distribuições diferentes, ainda que correlacionadas. Assim, há uma transferência de domínio na classificação. Eles implementaram um recurso de redes de aprendizado baseado em ELM para transferir os dados de treino e teste para o mesmo espaço, mas de forma que minimiza-se a distância entre os domínios. Desta forma, os dados transferidos conseguem ser usados para treinar um classificador ELM adaptativo.

7) ELM para "Transfer Learning": Datasets com anotações (linhas e colunas que não são atributos ou as próprias classes) desempenham um papel importante nas inteligências artificiais. O problema é que coletar dados rotulados é, comumente, uma tarefa de alto custo de tempo e de dinheiro. Com isso, o aprendizado por transferência tem uma força única na solução desse problema. Transferindo conhecimento do domínio fonte para o domínio alvo, podemos implementar o "transfer learning" (TL) com apenas um pequeno dataset anotado. Isso se torna adequado para campos com anotações de dados em falta, como diagnóstico auxiliado por computador, transporte e reconhecimento de emoções. Assim, o ELM vem sendo cada vez mais usado devido a sua velocidade de aprendizado (rápida) e fácil realização. Em 2013, Chen e Wang [47] aplicaram ELM online sequenciais nos esquemas de TL para reconhecimento vários modos de transporte. O esquema deles consistia de três etapas:

1) Treinar um ELM original no domínio fonte.
2) Calcula-se a média e o desvio padrão no processo de extração de dados confiáveis desse domínio fonte.
3) Aplicar ELM online sequenciais para retreinar o ELM classificador original.

Segundo os dados experimentais dos próprios autores, essa abordagem obteve uma performance melhor que outros métodos convencionais. Em 2015, Zhang e Zhang [48] propuseram uma estrutura universal para melhoria da capacidade de generalização de ELM tradicionais. Os autores aplicaram os métodos de adaptação nos domínios fonte e alvo para aprimorar a habilidade de interminínios do ELM e, com isso, afirmaram alcançar um estado da arte experimental. Posteriormente, modificaram esse modelo e testaram no campo de compensação de deriva em sensores de narizes eletrônicos [49] e, também, no adaptação dos domínios por conhecimento visual [50], provando a eficiência e o potencial da estrutura criada por eles. Em 2016, Li e Mao [51] apresentaram um método baseado em ELM para implementar uma abordagem de "transfer learning" para a tarefa de classificação de dados. As etapas foram tal que:

1) Um classificador ELM foi treinado com dados do domínio fonte, primeiramente e, durante esse processo, eles construíram dois parâmetros de penalidade diferentes.
2) Os autores aplicaram esses dois parâmetros (já computados) para obter os parâmetros restantes do Lagrangiano derivado com dados do domínio alvo.

3) Assim, o classificador ELM original foi otimizado e o conhecimento foi transferido entre os domínios.

Com os resultados experimentais, os autores demonstraram a eficiência da abordagem. Posteriormente, Li e Mao [52] melhoraram, ainda mais, a abordagem deles introduzindo uma representação esparsa livre de dados não rotulados e afirmaram, também, trazer resultados promissores.

8) ELM para Aprendizados Semi-supervisionado e Não Supervisionados: Ainda que seja um modelo de Aprendizado Supervisionado, ELM também foi aplicado em tarefas de aprendizado dos tipos Semi-supervisionado (SSL) e Não Supervisionado (UL). Liu e Xia [53] combinaram regulação múltipla com ELM para SSL, em que deram uma análise profunda na relação entre a regulação múltipla e o ELM e propuseram um modelo combinando esses dois objetos (ELM de múltipla regulação - MRELM). Enquanto mantinham recursos de um ELM tradicional, MRELM pode ser aplicado a dataset de larga escala. Resultados experimentais mostram que o MRELM proposto é superior aos tradicionais métodos de SSL em termos de escalabilidade e generalização. Krishnasamy e Paramesran [54] descobriram que uma regulação do ELM pelo Laplaciano falha em habilidades de extrapolação e propuseram um novo algoritmo para SSL chamado "Hessian semi-supervised ELM" (HSS-ELM). HSS-ELM usa uma regulação pela Hessiana que preserva a estrutura de múltipla regulação e melhora a habilidade de extrapolação do modelo, enquanto mantém os principais recursos de um ELM convencional. A implementação de um aprendizado multiclasse também foi simples. Liu e Liu [55] estudaram aprendizados com kernéis não paramétricos (NPKL) e apontaram que o método tradicional de NPKL regularmente requer múltiplas assunções e falta escalabilidade. Com isso, os autores implementaram ELM para o NPKL, o que pôde obter um kernel de matriz de baixo rank, a partir das amostras, sem uma múltipla estrutura clara. Mehrizi e Yazdi [56] combinaram um mapa evolutivo auto-organizável (GSOM) com ELM. Eles fizeram uso do ELM para resolver os parâmetros de calibração do GSOM, o que substancialmente aumentou a velocidade e melhorou a performance de classificação. Zhang and Ding [57] introduziram uma análise segundo onduletas ("wavelet analysis") para ELM em SSL e UL. Ding and Zhang [58] implementaram, ainda, ELM como um "autoencoder" para "feature learning" e representações esparsas. Os recursos integrados foram usados em um ELM não supervisionado para clustering. Zhu e Miao [59] estudaram estruturas de deep learning e propuseram um ELM autoencoder (ELM-AE) para representação de recursos a partir de imagens não rotuladas. ELM-AE foi usada para extrair representações de baixa hierarquia em campos perceptivos locais e os recursos aprendidos eram alimentados na última camada (chamada de "trans-layer" para "feature learning" de alto nível). O histograma de blocos foi implementado para alcançar invariância por translação e por rotação para a extração de representações. Experimentos conduzidos em MNIST e Caltech 101 sugeriram a efetividade desse método proposto. Cheng e Liu [60] melhoraram o ELM-AE e o aplicaram no K-SVD. Eles implementaram uma redução profunda de ruído ELM-AE (DDELM-AE) pela inicialização ortonormal do peso de entrada. Comparado com uma inicialização randômica, a ortogonalização alcançou projeções melhores no espaço de recursos do ELM e melhoraram a performance. Sun e Zhang [61] adicionaram termos de regulações múltiplas na função objeto ELM-AE e propuseram um ELM generalizado e "autoencoder" (GELM-AE). Ademais, desenvolveram uma nova rede profunda baseada em GELM-AE que converge mais rapidamente que as redes profundas convencionais. Nayak e Das [62] usaram ELM-AE para formar um ELM multicamadas e implementaram "leaky rectified linear unit" (LReLU) como função de ativação, de tal forma que:

$$LReLU(x) = \begin{cases} x, & x > 0 \\ ax, & x \leqslant 0 \end{cases}$$

onde $a \in (0, 1)$ é um hiperparâmetro. Yousefi-Azar e McDonnell [63] propuseram uma abordagem híbrida para SSL, empregando convolução e agrupamento para extrair recursos de imagens (usadas como input) e usaram ELM como o classificador. She e Hu [64] propuseram o uso de ELM hierárquicos para aprender recursos de EEG e aplicar ELM semi-supervisionado na classificação. Xia e Wang [65] estudaram OS-ELM e desenvolveram um modelo de OS-ELM semi-supervisionado baseado na densidade e que pode aprender padrões usando amostras não rotuladas.

9) Tabela de Variantes: Após analisar diversas variantes de ELM, os autores construíram um sumário de variantes de ELM de tal forma que não conseguimos pôr aqui por motivos de formatação do modelo de artigo da IEEE, não conseguimos reproduzir de forma satisfatória a tabela aqui. Assim, indicamos a leitura do artigo original. Contudo, conseguimos extrair e expressar a ideia de que o ELM, em sua forma original, tem um propósito bem definido: ter uma implementação simples, boa eficiência e rápida computação. Claro que, quanto mais se pesquisa sobre esse modelo, podemos achar variantes que retornem melhores recursos. Isto faz com que consigamos até atingir uma performance geral melhor que outros modelos de aprendizado em seu estado da arte.

C. ELM vs Outros Algoritmos

Diante de vários modelos de Aprendizado de Máquina (AM), é natural (segundo a tendência científica AM) que façamos a comparação de desempenho entre o ELM e os modelos de estado da arte de AM como "Support Vector Machine" (SVM), "Redes Neurais Aleatórias" (RNN), "Redes Neurais Baseadas em Funções Radiais" (RBFNN), "Redes Neurais de Hopfield" (HNN), "Máquina de Boltzmann" (BM), "Máquina de Boltzmann Restrita" (RBM), "Deep Belief Network" (DBN) e até outros modelos de Deep Learning. Dizemos que esses modelos estão no estado da arte do AM, pois não só representam pilares importantes na história da sua evolução, mas também por serem usados em pesquisas até hoje, principalmente, para

compararmos a robustez, a eficiência e a performance de um dado classificador em estudo, como, no caso, o ELM, com esses modelos já bem conhecidos. É através dessas comparações que a gente consegue entender o sentido e o lugar do ELM no mundo do AM: um modelo de rápido aprendizado, simples implementação e com uma performance sólida. Isso se dá pelo fato das variáveis se tornarem cada vez mais robustas e, consequentemente, atribuem ao ELM uma boa acurácia.

1) ELM vs SVM: Um dos casos mais conhecidos da lista de modelos de classificação, o SVM foi proposto por Cortes e Vapnik [66] em 1995. Basicamente falando, o espaço de trabalho do SVM é uma hiperforma com n classes $\{y_1, y_2, ..., y_n\}$ associadas a um conjunto de atributos, respectivamente. Isto é, dado que m é a cardinalidade de cada vetor de atributos $\vec{x}_j$, temos um subespaço com dimensão dada por γ (note que γ não necessariamente é igual para todas as classes, uma vez que podemos ter datasets desbalanceados). Assim, poderíamos separar cada classe y_j por hiperplanos parametrizados e treinados (para o SVM Linear) usando os atributos $\vec{x}_j^k = (x_{1j}, x_{2j}, ..., x_{mj})^k$, onde k é o índice que percorre todo o conjunto de possíveis vetores da classe y_j. De posse desses hiperplanos, podemos obter aquele que maximiza a distância entre classes próximas ao plano, de forma que esse hiperplano pode distinguir muito bem os pontos de dados. Dado que queremos distinguir hiperplanos do tipo $X_i^T w + b = 0$ (onde X_i denota $\vec{x_i}$), podemos supor um par de hiperplanos de forma que separamos duas classes $y = \pm 1$:

$$\begin{cases} X^T w + b = +1 \\ X^T w + b = -1 \end{cases}$$

e obtemos o que chamamos de *margem* em SVM, que, por definição, é a distância a ser otimizada entre o hiperplano e os pontos de dados: $margem = \frac{2}{||w||} \iff$ para maximizar a margem, precisamos minimizar $\frac{1}{2}||w||^2$. Ademais, para cada i, precisamos que $|y_i(X_i^T + b)| \geqslant 1$, i.e.:

$$\begin{cases} (X_i^T + b) \geqslant 1, \ y = 1 \\ (X_i^T + b) \leqslant 1, \ y = -1 \end{cases}$$

Assim, a expressão matemática do objetivo do SVM Linear é:

$$min \frac{1}{2}||w||^2, s.t. \ y_i(X_i^T + b) \geqslant 1, \ i \in \{1, 2, ..., n\}$$

Contudo, resolver essa expressão não é muito fácil e, por tal, comumente minimizamos usando multiplicadores de Lagrange. Seja $L(w, b, \alpha)$ a função de Lagrange, em que $\alpha_i \geqslant 0$, $i \in \{1, 2, ..., n\}$ são os multiplicadores de Lagrange. Logo, na equação do SVM Linear:

$$L(w, b, \alpha) = \frac{1}{2}||w||^2 - \sum_{i=1}^{n} \alpha_i [y_i(X_i^T w + b) - 1]$$

que, quando todas as condições de restrição são obedecidas $\implies L(w, b, \alpha) = \frac{1}{2}||w||^2$, i.e, a otimização da margem resulta na mesma coisa que otimizar sua lagrangeana associada. Claro que essa formulação matemática muda quando mudamos o tipo de hiperforma de separação. Huang e Ding [6] apresentaram uma análise detalhada e comparativa entre SVM e ELM. Foi revelado a teoria de margem máxima do SVM e da mínima norma do peso da rede estão em conformidade com o ELM. Em problemas de classificação, ELM e SVM são equivalentes, com o ELM levando vantagem por possuir menos restrições de otimização, o que tende a performar melhor. Ademais, ELM é mais robusto para fatores definidos pelo usuário. Posteriormente, Huang e Zhou [7] compararam ELM com o SVM de mínimos quadrados (LS-SVM) e, também, com o "proximal SVM" (PSVM) em diversos tipos de datasets. Eles descobriram que o SVM pode ser considerado como uma forma unificada do LS-SVM e PSVM. Ainda, a performance do ELM para problemas de classes binárias era similar ao desempenho de LS-SVM e PSVM. Já em problemas de multiclasse, ELM performou substancialmente melhor. Ainda, pelo recurso de mapeamento randômico do ELM, sua velocidade de convergência é milhares de vezes maior e o ELM obtém não-linearidade e a habilidade de aproximação global. Liu e Loh [67], em 2005, fizeram um comparativo entre SVM e ELM na tarefa de classificação de textos e seus experimentos demonstraram que o SVM se saiu melhor na maioria das categorias de avaliação, especialmente na pontuação F-1. Em 2014, Chorowski e Wang [68] apresentaram uma pesquisa de implementar uma estrutura de otimização convexa para avaliar diferentes modelos de AM, incluindo ELM e SVM. Zhong e Miao [69] compararam diversos métodos de AM para a tarefa de avaliação de crédito corporativo. Segundo os experimentos dos autores, SVM teve a maior acurácia, enquanto SLFN mostraram melhor robustez. O ELM provou sua força na eficiência, simplicidade e rapidez. Em 2015, Qiu e Wang [70] investigaram vários métodos de predição de status de qualidade do mandarim. Eles descobriram que o ELM e o Random Forest mostraram uma melhor performance de predição que o SVM. Em 2016, Zhang e Zhang [71] realizaram experimentos para buscar o melhor classificador para características profundas extraídas por redes neurais convolucionais. Os autores afirmaram que o ELM mostrou uma óbvia superioridade em tarefas de reconhecimento inter-dominiais e kernel ELM atingiu performance de estado da arte. Em 2017, Olatunji [5] comparou ELM com SVM para tarefa de classificação de spam em emails e, de acordo com os experimentos, SVM foi mais acurado, enquanto ELM foi mais rápido.

2) ELM vs RNN: A Rede Neural Aleatória (RNN) é um tipo especial de rede neural proposta por Erol Gelenbe em 1989 [72]. A RNN foi inspirada pela simulação de como as redes neurais biológicas recebem e emitem sinais de estímulos, comandados por cada neurônio. Dessa forma, a RNN é composta por uma rede neural aberta consistindo de vários neurônios, onde cada neurônio recebe um sinal e se o sinal for positivo sua saída será um e se for negativa sua saída será menos um, o processo de emitir e receber sinal ocorre continuamente por toda a rede até a mesma chegar em uma condição de equilíbrio. Ao realizar a comparação do RNN com ELM, diversos estudos mostraram

que a ELM supera a RNN em várias aplicações, indicando que a ELM apresenta vantagens como maior precisão e menor custo de treinamento em comparação com a RNN e outras estruturas de redes neurais.

3) ELM vs RBFNN: A Rede Neural Baseada em Funções Radiais (RBFNN) é uma rede neural com uma única camada oculta, proposta no final dos anos 1980 por Broomhead e Lowe [73]. Ela é reconhecida por sua capacidade de aproximação de funções e forte habilidade de generalização, sendo utilizada em classificações de padrões, aproximação de funções e mineração de dados. A RBFNN utiliza a função de base radial na camada oculta para transformar os dados para um espaço de dimensão maior para realizar uma separação linear de problemas não separáveis linearmente em espaços de baixa dimensão. A rede é estruturada em três camadas: uma camada de entrada, uma camada oculta e uma camada de saída, sendo que a ligação entre a camada de entrada e a oculta é direta, ou seja, com peso unitário.

A comparação entre ELM e RBFNN foi objeto de vários estudos. Em 2006, Li e Huang [74] conduziram um estudo para comparar a ELM e a RBFNN na aplicação de equalização de canal. Os resultados mostraram que a ELM supera a RBFNN, apresentando uma taxa de erro de símbolo menor e maior velocidade de aprendizado.

Além de estudos de comparação, houveram estudos para integrar as vantagens de ambas as técnicas para criar um modelo combinado. Assim, em 2011, Fernandez-Navarro e Hervas-Martinez [75] propuseram um modelo inovador que usa a ELM como método de treinamento e incorporava uma rede neural de função de base radial generalizada (GRBF), esse modelo foi nomeado Máquina de Aprendizagem Extrema-Generalizada de Base Radial (MELM-GRBF). A MELM-GRBF se mostrou superior tanto a ELM quanto a RBFNN isoladamente. Uma outra abordagem foi desenvolvida por Ding e Ma, na qual propuseram uma estratégia de treinamento autoadaptativa para a RBFNN utilizando a ELM, que apresentou vantagens significativas em relação a outros modelos.

4) ELM vs HNN: A Rede Neural de Hopfield (HNN) foi proposta em 1982 por Hopfield [76] com o objetivo de resolver problemas de reconhecimento de padrões e otimizações. A HNN é um tipo de rede neural recursiva com conexões de feedback que permitem a retroalimentação da saída a entrada, é uma rede interconectada, ou seja, cada neurônio é interconectado com todos os outros neurônios. Ela combina elementos de sistemas de armazenamento e sistemas binários, e é uma rede que garante convergência para um mínimo local, e dessa forma há riscos de converter para um mínimo errado em vez do mínimo global. A HNN é um modelo que simula a memória humana, onde a saída é constantemente retroalimentada a entrada, resultando em mudanças de estado até alcançar um estado de equilíbrio estável.

A HNN pode ser dividida em dois tipos: Discreta (DHNN) e contínua (CHNN). Apesar de modelos mais avançados baseados na HNN terem se popularizado, existiram estudos comparando a HNN com a ELM. Lian e Cheng [77] propuseram um modelo modificado baseado na ELM, afirmando ser superior a HNN. Liu e Liu [78] desenvolveram uma ELM com múltiplas camadas ocultas e técnicas de buscas aleatórias mostrando vantagens em velocidade de treinamento e precisão comparada com a HNN.

5) ELM vs BM: A HNN é conhecida por sua capacidade de otimização, porém frequentemente encontra dificuldades de otimização como a convergência para mínimos locais em vez de mínimos globais. Para resolver esse problema, introduziu-se fatores estocásticos na rede, permitindo que a rede aceite aumentos na função de energia para potencialmente escapar de regiões de mínimos locais.

O algoritmo Máquina de Boltzmann (BM) é uma técnica eficaz para abordar o problema dos mínimos locais em redes estocásticas. O algoritmo foi inspirado no processo de recozimento de metais, e realizando uma analogia, o algoritmo aumenta a temperatura para promover alta energia e permitir uma maior exploração e é seguido por um resfriamento lento que permite que a rede estabilize no estado de menor energia interna. A técnica BM foi introduzida por Ackley e Hiton em 1985, e consiste de uma rede com unidades ocultas, unidades visíveis e arestas de dependências. O algoritmo serviu como base para a criação de modelos mais complexos e conhecidos, como Máquina de Boltzmann Restrita (RBM) e Máquina de Boltzmann Profunda (DBM). A comparação da ELM com tais modelos será feita nas seções seguintes.

6) ELM vs RBM: A Máquina de Boltzmann Restrita (RBM) é uma rede neural que aprende distribuições de probabilidade a partir de conjuntos de dados de entrada. Foi originalmente nomeada Harmonium por Paul Skitksy em 1986 e ganhou destaque como um algoritmo de aprendizado rápido na metade dos anos 2000 através do desenvolvimento de Hinton e Salakhutdinov. O algoritmo é principalmente aplicado na redução de dimensão, classificação, filtragem colaborativa, aprendizado de características e modelagem e tópicos, podendo ser treinada tanto de forma supervisionada quanto não supervisionada.

A RBM é uma variação da Máquina de Boltzmann que emprega uma estrutura espacial com uma camada visível e múltiplas camadas ocultas, as unidades visíveis e ocultas são usadas para expressar o modelo de aprendizagem de rede aleatória e o ambiente aleatório, e a cada nó está associado a um peso, refletindo a correlação entre as unidades visíveis e ocultas. O modelo avança a informação através das camadas em um processo hierárquico e não supervisionado, criando uma representação dos dados mais complexa e abstrata.

Na literatura, diversas pesquisas demonstram a eficácia da RBM em comparação e em combinação com outros métodos. A combinação da RBM com a ELM mostrou ser mais eficiente que a aplicação da Análise de Componentes Principais (PCA) com ELM em processamento espectral. Além disso, em estudos de detecção automática de apneia do sono a ELM mostrou-se superior a métodos que incluíam RBM e outras técnicas de classificação.

Chen e Yang desenvolveram uma metodologia que inte-

gra RBM e ELM para gerenciamento de grandes volumes de dados, inserindo nós ocultos na ELM tradicional e alcançando desempenhos superiores. Em 2017, Ramasamy e Rajaraman introduziram uma versão modificada da RBM, chamada de Máquina de Boltzmann Restrita Metacognitiva (McRBM), que se mostrou superior a técnicas como ELM e SVM, e também demonstraram que a RBM pode ser utilizada para melhorar a performance da ELM pal determinação dos pesos de entrada. Wang e Zhang exploraram métodos para treinar redes neurais *feedforward* com múltiplas camadas ocultas, e destacaram as vantagens da RBM em termos de velocidade de treinamento, generalização e compreensibilidade em comparação com a Backpropagation e a ELM.

7) ELM vs DBN: A Rede de Crença Profunda (DBN) é uma rede neural usada em aprendizado de máquina para aprendizado supervisionado e não supervisionado. Foi proposto por Hinton e Osindero, e é um modelo probabilístico de geração que estabelece uma distribuição conjunta entre dados observacionais e rótulos, permitindo não só a identificação de características e classificação de dados, mas também a geração de dados. Ela se mostrou eficiente nas aplicações de reconhecimento de escrita, reconhecimento de fala e processamento de imagens.

A arquitetura da DBN inclui múltiplas camadas de neurônios, divididos em neurônios dominantes e recessivos, ou unidades visíveis e ocultas, onde as unidades ocultas funcionam como detectores de características e as unidades visíveis são usadas para aceitar a entrada. As conexões entre as camadas superiores são não direcionadas e formam uma memória associativa, e existem conexões diretas entre camadas inferiores e superiores.

A DBN é composta por Máquinas de Boltzmann Restritas (RBM), e seu treinamento é realizado camada por camada, onde cada RBM pode operar individualmente como um agrupamento. O processo de treinamento inclui etapas que vão desde o treinamento completo da primeira RBM até o treinamento conjunto de unidades visíveis e neurônios de classificação da cauda superior, caso os dados de treinamento tenham rótulos.

Desde a sua proposição, a DBN tem sido aprimorada, incluindo integração com a ELM para melhorar o seu desempenho. Yu e Zhuang desenvolveram uma arquitetura modificada de ELM, aplicando uma representação de nível profundo para realizar uma generalização empilhada, e demonstraram que essa abordagem supera métodos tradicionais, incluindo o DBN. Zhang e Ding melhoraram a ELM com o uso das representações profundas alcançando desempenho superior ao método DBN. Ronoud e Asadi introduziram uma metodologia que combina ELM e DBN para detectar câncer de mama, mostrando resultados superiores a outros métodos combinados como DBN com algoritmo genético. Além disso, Zhang e Xiao propuseram uma abordagem baseada em ELM, chamada ELM de probabilidade multicamada (MPELM), para localização, indicando que esta era mais eficaz do que métodos populares, incluindo DBN e Deep Boltzmann Machine (DBM).

8) ELM vs Outros Modelos de Deep Learning: Kasun e Zhou combinaram um autoencoder com a ELM propondo a ELM-AE, eles desenvolveram uma ELM de cinco camadas e realizaram experimentos com o conjunto de dados MNIST. Os resultados mostraram que o ELM multicamadas era comparável a DBN e a DBM, com a vantagem de exigir menos tempo de treinamento. Zhao e Jiao combinaram operações tensoriais com ELM e propuseram a máquina de aprendizado extremo de tensor profundo e esparso (SDT-ELM), qua alcançou bom desempenho de classificação em três conjuntos de dados abertos. Shen e Xiao sugeriram a hibridização entre CNN profunda e ELM para classificação de imagens hiperespectrais. Eles projetaram um módulo de convolução de duas ramificações para extração de características espaciais e espectrais, respectivamente, assim, as características geradas foram concatenadas e enviadas para um ELM empilhado para classificação, e os resultados revelaram que o método alcançou bom desempenho com maior velocidade.

D. Tarefas do ELM

Já que o ELM possui muitas vantagens comparada a outros algoritmos de Machine Learning, ela vem sendo usada extensivamente para resolver problemas do mundo real.

1) Reconhecimento: O ELM se tornou uma importante e eficiente ferramenta para o reconhecimento de objetos.

Dentre os trabalhos publicados relacionados ao ELM na área de reconhecimento podemos destacar Chacko e Vimal Krishnan [79] que utilizaram ELM como algoritmo de classificação para reconhecimento de caracteres manualmente escritos. Em seguida, Rong e Jia [80] desenvolveram um sistema de reconhecimento de aeronaves baseado em ELM. O ELM tambem foi usado para diversas outras aplicações, como reconhecer defeitos em tecidos [81], reconhecimento de atividades de sensores [82], detecção de falhas [83] e até mesmo para reconhecimento de expressões faciais [84].

2) Predição: Aqui podemos ressaltar o trabalho de Yang e Yan [85] para predição de pressao nos gasodutos de pastas de carvão. Zhang e Liu [86] utilizaram ELM para prever a temperatura de fusão para polimerização de propeno. Outras contribuições notáveis foram a previsão de temperatura e humidade em estufas [87], de rediação solar [88], precificação de carbono [89] e até preço de energia elétrica [90].

3) Representation/Feature Learning: Zhang e Ding [91] propuseram um esquema hibrido para aprendizado de features e classificação. Uma Deep Belief Network foi usada para treinamento das features enquanto o ELM foi utilizado para o mapeamento das features. Outra variação do ELM foi proposta por Chen e Song [92], na qual propuseram um ELM baseado no metodo de transferencia de features. De início, como um ELM comum, o mapeamento aleatório foi utilizzado para gerar features a partir da entrada para ambos a fonte e o objetivo. Entao, domain transfer foi utilizado com o objetivo de minimizar a distancia do domínio e preservar as informações no domínio do

objetivo ao máximo. Finalmente, as features transferidas foram utilizadas para treinar uma ELM adaptativa para classificação. Outra pesquisa a se destacar foi a de Pei e Wang [93], na qual eles utilizaram ELM para treinamento de features label-specific.

4) Clustering: Os pesquisadores estão cada vez mais se interessando no uso do ELM para clustering, que é um problema do aprendizado nao supervisionado. He e Jin [94] descobriram que o mapeamento de features do ELM foi superior a função base de kernel de Mercer para clustering. Alshamiri e Singh [95] utilizaram colonias artificiais de abelhas para treinar projeção de features do ELM. O sistema proposto superou a inicialização aleatória nos cluster centers. Huang e Yu [96] sugeriram o uso de gaussianas e neurônios sigmóides na camada oculta do ELM para aprendizado de features.

5) Surrogate Modeling: O ELM vem sido utilizado como um meta-modelo ou um Surrogate Model, uma aplicação de aprendizado de máquina supervisionado utilizada quando o resultado de interesse não pode ser lido ou avaliado diretamente. Pavelsky e Delgado [97] tentaram se aproveitar do ELM para resolver problemas de otimização com vários objetivos. Eles propuseram um método surrogate-assisted baseado em ELM, o qual atingiu a performance state-of-art nas simulações. Ghiasi e Ghasemi [98] propuseram dois algoritmos para detectar danos a estruturas e se utilizaram de 10 surrogate models, incluindo o ELM.

E. Aplicações do ELM

Dada a sua superioridade em velocidade de treinamento, acurácia e generalização, o ELM é aplicado em diversos campos de atuação, desde medicina até economia e transportes.

1) Medicina: Dentro da medicina, seu uso se popularizou dentro da área de criação e análise de imagens. Problemas como ressonância magnética [99,100,101], ultrassonografia [102,103], mamografia [104,105,106] e tomografia computadorizada [107,108,109] são as aplicações mais populares.

2) Robótica: Na área da robótica o ELM se popularizou no controle de movimentos robóticos. Alcin e Ucar [110] utilizaram ELM no controle de braços robóticos e afirmaram que sua abordagem superou a que utilizava artificial neural network (ANN). Em 2019 Duan e Ou [111] construiram um sistema dinâmico de controle de movimentos robóticos. Eles demonstraram, através de seus experimentos, que a eficiência e acurácia do ELM tornaram a abordagem melhor que as demais.

3) Economia: Em 2012, Landa-Torres e Ortiz-Garcia [112] propuseram um método baseada no ELM para avaliar o sucesso internacional de empresas. Em 2016, Sokolov-Mladenović e Milovančević [113] aplicaram ELM para prever crescimento da economia baseado em dados de ações, importação e exportação. Em seguida, Sokolov-Mladenović e Milovančević [114] usaram dados de agricultura e industria com o mesmo objetivo. Foi utilizada uma artificial neural network (ANN) com back propagation (BP) para contraste e foi concluído que ELM foi superior a abordagem de contraste.

Muitos pesquisadores também aplicaram ELM para analizar a relação entre emissões de CO2 com o desenvolvimento econômico [115,116,117].

4) Transporte: Dentro da área de transporte ELM foi aplicada principalmente para resolver problemas como otimização de rotas. Como por exemplo, Wang e Chow [118] utilizaram data em larga escala para ajudar motoristas de táxi a encontrarem o melhor trajeto. Outro exemplo é Sun e Ng [119] que propuseram uma abordagem de 2 passos usando linear programming (LP) e ELM para otimizar um sistema de transporte. Seus experimentos provaram que sua abordagem poderia melhorar o tempo de vida dos sistemas e aumentar a sua confiança.

Pesquisadores também utilizaram ELM para predição de tráfegos em rotas, tanto para motoristas quanto para auxílio de planejamento do governo [84,120].

5) Geral: Dada a sua alta velocidade de treinamento e boa capacidade de generalização, podem ser observadas diversas aplicações do ELM nos mais diversos campos de conhecimento humano. Áreas como química [121,122], internet das coisas [123,124], geografia [125,126] e indústria alimentícia [121,127] também ganharam destaque dentro das aplicações do ELM.

F. Controvérsia do ELM

Vale ressaltar, porém, que dois revisores anônimos sugeriram algumas controvérsias relacionadas ao ELM.

A ideia de aleatorizar alguns dos pesos para reduzir a complexidade do treinamento não é nova. Essa técnica teria sido previamente aplicada na Schmidt Neural Network (SNN) proposta por Schmidt and Kraaijveld [128] e também na Random Vector Functional Link Net (RVFL) proposta por Pao and Park [129], ambas publicadas mais de 10 antos antes do ELM.

A outra controvérsia é que o ELM, além de poder ser considerado uma variação da RVFL, é quase igual ao SNN. A única diferença entre eles é que o SNN possui a possibilidade de treinar o seu viés de saída, enquanto o viés de saída do ELM é sempre zero.

V. Conclusão

Nessa revisão vimos o desenvolvimento e aplicações do ELM nas últimas décadas. Como conseguimos ver, dada a sua simples implementação, alta velocidade e boa eficiência o ELM se tornou bastante popular e é comumente preferido em relação a outras abordagens de inteligência artificial. Com o decorrer dos anos, estamos sendo apresentados a variantes que aprimoram o modelo, tornando o modelo cada vez mais uma opção sólida dentro da área de aprendizagem de máquina.

O ELM tem um grande potencial para se tornar mais importante na área de Big Data. A combinação de ELM com Deep Learning pode fornecer resultados semelhantes ao que o próprio Deep Learning atualmente apresenta.

Porém, apresentando um tempo de treinamento menor, problema comum em Big Data devido ao grande volume de dados.

Além disso, a justificativa teórica do ELM está em constante análise e evolução. O mapeamento aleatório nas camadas ocultas é a ideia mais significante do ELM, que contribui principalmente para sua alta velocidade de treinamento. Porém, ainda há a necessidade da justificativa da aleatoriedade. Vale a pena um estudo mais profundo para comparar o ELM com outros mecanismos que também usam a aleatoriedade como base de sua tecnologia, como o Random Forest.

Finalmente, uma direção interessante para o desenvolvimento do ELM está conectado ao aprendizado bio-inspirado. Pesquisadores descobriram que os nossos neurônios também utilizam um mecanismo aleatório para o seu aprendizado [130]. Já que redes neurais artificiais são originalmente baseadas no funcionamento dos nossos cérebros, será interessante investigar a conexão do ELM com algoritmos bio-inspirados.

Referências

[1] J. Wang, S. Lu, S.-H. Wang e Y.-D. Zhang, "A review on extreme learning machine," *Multimedia Tools and Applications*, vol. 81, pp. 41611–41660, Dec 2022.

[2] G.-B. Huang, Q.-Y. Zhu e C.-K. Siew, "Extreme learning machine: Theory and applications," *Neurocomputing*, vol. 70, no. 1, pp. 489–501, 2006. Neural Networks.

[3] S. Keskin, A. Durdu, M. F. Aslan e A. Yusefi, "Performance comparison of extreme learning machines and other machine learning methods on wbcd data set," em *2021 29th Signal Processing and Communications Applications Conference (SIU)*, pp. 1–4, 2021.

[4] C. Shen, S. Zhang, J.-H. Zhai, D.-S. Luo e J.-F. Chen, "Imbalanced data classification based on extreme learning machine autoencoder," *2018 International Conference on Machine Learning and Cybernetics (ICMLC)*, vol. 2, pp. 399–404, 2018.

[5] S. O. Olatunji, "Extreme learning machines and support vector machines models for email spam detection," *2017 IEEE 30th Canadian Conference on Electrical and Computer Engineering (CCECE)*, pp. 1–6, 2017.

[6] G.-B. Huang, X. Ding e H. Zhou, "Optimization method based extreme learning machine for classification," *Neurocomputing*, vol. 74, no. 1, pp. 155–163, 2010. Artificial Brains.

[7] G.-B. Huang, H. Zhou, X. Ding e R. Zhang, "Extreme learning machine for regression and multiclass classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 42, no. 2, pp. 513–529, 2012.

[8] S. Al-Hammouri, M. Fora e M. Ibbini, "Extreme learning machine for melanoma classification," em *2021 IEEE Jordan International Joint Conference on Electrical Engineering and Information Technology (JEEIT)*, pp. 114–119, 2021.

[9] V. V. Vardhan Reddy, U. P. P. S e S. K. Tiwari, "Precise medical diagnosis for brain tumor detection and data sample imbalance analysis using enhanced kernel extreme learning machine model with deep belief network compared to extreme machine learning," em *2022 14th International Conference on Mathematics, Actuarial Science, Computer Science and Statistics (MACS)*, pp. 1–9, 2022.

[10] M. Zhou e W. Ai, "Distributed reduced kernel extreme learning machine," em *2021 China Automation Congress (CAC)*, pp. 3384–3387, 2021.

[11] Y. Liu, W. Cao, Y. Liu, D. Li e Q. Wang, "Ensemble online sequential extreme learning machine for air quality prediction," em *2021 IEEE 7th International Conference on Control Science and Systems Engineering (ICCSSE)*, pp. 233–237, 2021.

[12] A. Bardhan, P. Samui, K. Ghosh, A. H. Gandomi e S. Bhattacharyya, "Elm-based adaptive neuro swarm intelligence techniques for predicting the california bearing ratio of soils in soaked conditions," *Appl. Soft Comput.*, vol. 110, p. 107595, 2021.

[13] X. Tang e L. Chen, "Artificial bee colony optimization-based weighted extreme learning machine for imbalanced data learning," *Cluster Computing*, vol. 22, 05 2019.

[14] N. Kardani, A. Bardhan, B. Roy, P. Samui, M. Nazem, D. J. Armaghani e A. Zhou, "A novel improved harris hawks optimization algorithm coupled with elm for predicting permeability of tight carbonates," *Engineering with Computers*, vol. 38, pp. 4323 – 4346, 2021.

[15] N. Kardani, A. Bardhan, P. Samui, M. Nazem, A. Zhou e D. J. Armaghani, "A novel technique based on the improved firefly algorithm coupled with extreme learning machine (elm-iff) for predicting the thermal conductivity of soil," *Engineering with Computers*, vol. 38, pp. 3321 – 3340, 2021.

[16] H. Patil e K. Sharma, "Extreme learning machine: A comprehensive survey of theories & algorithms," em *2023 International Conference on Computational Intelligence and Sustainable Engineering Solutions (CISES)*, pp. 749–756, 2023.

[17] G.-B. Huang, L. Chen e C.-K. Siew, "Universal approximation using incremental constructive feedforward networks with random hidden nodes," *IEEE Trans. Neural Netw.*, vol. 17, pp. 879–892, July 2006.

[18] Z. Xu, M. Yao, Z. Wu e W. Dai, "Incremental regularized extreme learning machine and its enhancement," *Neurocomputing*, vol. 174, pp. 134–142, Jan. 2016.

[19] N. Liu e H. Wang, "Ensemble based extreme learning machine," *IEEE Signal Process. Lett.*, vol. 17, pp. 754–757, Aug. 2010.

[20] E. Soria-Olivas, J. Gómez-Sanchis, J. D. Martín, J. Vila-Francés, M. Martínez, J. R. Magdalena e A. J. Serrano, "BELM: Bayesian extreme learning machine," *IEEE Trans. Neural Netw.*, vol. 22, pp. 505–509, Mar. 2011.

[21] Y. Wang, F. Cao e Y. Yuan, "A study on effectiveness of extreme learning machine," 2014.

[22] J. Cao, Z. Lin e G.-B. Huang, "Self-adaptive evolutionary extreme learning machine," *Neural Process. Lett.*, vol. 36, pp. 285–305, Dec. 2012.

[23] X. Liu, L. Wang, G.-B. Huang, J. Zhang e J. Yin, "Multiple kernel extreme learning machine," *Neurocomputing*, vol. 149, pp. 253–264, Feb. 2015.

[24] W. Deng, Q. Zheng e K. Zhang, "Reduced kernel extreme learning machine," em *Proceedings of the 8th International Conference on Computer Recognition Systems CORES 2013* (R. Burduk, K. Jackowski, M. Kurzynski, M. Wozniak e A. Zolnierek, eds.), (Heidelberg), pp. 63–69, Springer International Publishing, 2013.

[25] K. Chen, Q. Lv, Y. Lu e Y. Dou, "Robust regularized extreme learning machine for regression using iteratively reweighted least squares," *Neurocomputing*, vol. 230, pp. 345–358, Mar. 2017.

[26] Q. Zhang, H. Li, C. Liu e W. Hu, "A new extreme learning machine optimized by firefly algorithm," em *2013 Sixth International Symposium on Computational Intelligence and Design*, IEEE, Oct. 2013.

[27] Y. Zhang, J. Wu, Z. Cai, P. Zhang e L. Chen, "Memetic extreme learning machine," *Pattern Recognit.*, vol. 58, pp. 135–148, Oct. 2016.

[28] D. R. Nayak, R. Dash e B. Majhi, "Pathological brain detection using extreme learning machine trained with improved whale optimization algorithm," em *2017 Ninth International Conference on Advances in Pattern Recognition (ICAPR)*, IEEE, Dec. 2017.

[29] M. Wang, H. Chen, H. Li, Z. Cai, X. Zhao, C. Tong, J. Li e X. Xu, "Grey wolf optimization evolving kernel extreme learning machine: Application to bankruptcy prediction," *Eng. Appl. Artif. Intell.*, vol. 63, pp. 54–68, 2017.

[30] Y. Zhang, J. Wu, C. Zhou e Z. Cai, "Instance cloned extreme learning machine," *Pattern Recognit.*, vol. 68, pp. 52–65, Aug. 2017.

[31] L. Zheng, Z. Wang, Z. Zhao, J. Wang e W. Du, "Research of bearing fault diagnosis method based on multi-layer extreme learning machine optimized by novel ant lion algorithm," *IEEE Access*, vol. 7, pp. 89845–89856, 2019.

[32] H. Gao, X.-W. Liu, Y.-X. Peng e S.-L. Jian, "Sample-based extreme learning machine with missing data," *Math. Probl. Eng.*, vol. 2015, pp. 1–11, 2015.

[33] Z. Bai, L. L. C. Kasun e G.-B. Huang, "Generic object recognition with local receptive fields based extreme learning machine," *Procedia Comput. Sci.*, vol. 53, pp. 391–399, 2015.

[34] W.-Y. Deng, Z. Bai, G.-B. Huang e Q.-H. Zheng, "A fast SVD-hidden-nodes based extreme learning machine for large-scale data analytics," *Neural Netw.*, vol. 77, pp. 14–28, May 2016.

[35] C.-S. Ouyang, Y.-Y. Cheng, T.-C. Kao, S.-T. Pan, C.-H. Wu e S.-J. Lee, "Recursive SVD-based fuzzy extreme learning machine," em *2017 IEEE International Conference on Information and Automation (ICIA)*, IEEE, July 2017.

[36] C. Wang, Y. Li, W. Zou e Y. Xia, "An incremental extreme learning machine prediction method based on attenuated regularization term," em *Advances in Swarm Intelligence: 13th International Conference, ICSI 2022, Xi'an, China, July 15–19, 2022, Proceedings, Part II*, (Berlin, Heidelberg), p. 189–200, Springer-Verlag, 2022.

[37] D. Wu, T. Li e Q. Wan, "A hybrid deep kernel incremental extreme learning machine based on improved coyote and beetle swarm optimization methods," *Complex Intell. Syst.*, vol. 7, pp. 3015–3032, Dec. 2021.

[38] G.-B. Huang, N. Liang, H.-J. Rong, P. Saratchandran e N. Sundararajan, "On-line sequential extreme learning machine.," vol. 2005, pp. 232–237, 01 2005.

[39] J. Zhao, Z. Wang e D. S. Park, "Online sequential extreme learning machine with forgetting mechanism," *Neurocomputing*, vol. 87, pp. 79–89, 2012.

[40] H. T. Huynh e Y. Won, "Regularized online sequential learning algorithm for single-hidden layer feedforward neural networks," *Pattern Recognit. Lett.*, vol. 32, pp. 1930–1935, Oct. 2011.

[41] B. Mirza, Z. Lin e K.-A. Toh, "Weighted online sequential extreme learning machine for class imbalance learning," *Neural Process. Lett.*, vol. 38, pp. 465–486, Dec. 2013.

[42] W. Zong, G.-B. Huang e Y. Chen, "Weighted extreme learning machine for imbalance learning," *Neurocomputing*, vol. 101, p. 229–242, 02 2013.

[43] P. Liu, Y. Huang, L. Meng, S. Gong e G. Zhang, "Two-stage extreme learning machine for high-dimensional data," *International Journal of Machine Learning and Cybernetics*, vol. 7, 08 2014.

[44] J. Xin, Z. Wang, L. Qu e G. Wang, "Elastic extreme learning machine for big data classification," *Neurocomputing*, vol. 149, pp. 464–471, 02 2015.

[45] R. Yang, S. Xu e L. Feng, "An ensemble extreme learning machine for data stream classification," *Algorithms*, vol. 11, p. 107, 07 2018.

[46] Y. Chen, S. Song, S. Li, L. Yang e C. Wu, "Domain space transfer extreme learning machine for domain adaptation," *IEEE Transactions on Cybernetics*, pp. 1–14, 04 2018.

[47] Z. Chen, S. Wang, Z. Shen, Y. Chen e Z. Zhao, "Online sequential elm based transfer learning for transportation mode recognition," em *2013 IEEE Conference on Cybernetics and Intelligent Systems (CIS)*, pp. 78–83, 2013.

[48] L. Zhang e D. Zhang, "Domain adaptation transfer extreme learning machines," em *Proceedings of ELM-2014 Volume 1* (J. Cao, K. Mao, E. Cambria, Z. Man e K.-A. Toh, eds.), (Cham), pp. 103–119, Springer International Publishing, 2015.

[49] L. Zhang e D. Zhang, "Domain adaptation extreme learning machines for drift compensation in e-nose systems," *IEEE Transactions on Instrumentation and Measurement*, vol. 64, no. 7, pp. 1790–1801, 2015.

[50] L. Zhang e D. Zhang, "Robust visual knowledge transfer via extreme learning machine-based domain adaptation," *IEEE Transactions on Image Processing*, vol. 25, no. 10, pp. 4959–4973, 2016.

[51] X. Li, W. Mao e W. Jiang, "Extreme learning machine based transfer learning for data classification," *Neurocomputing*, vol. 174, 08 2015.

[52] X. Li, W. Mao, W. Jiang e Y. Yao, "Extreme learning machine via free sparse transfer representation optimization," *Memetic Computing*, vol. 8, 06 2016.

[53] B. Liu, S.-X. Xia, F.-R. Meng e Z. Yong, "Manifold regularized extreme learning machine," *Neural Computing and Applications*, vol. 27, 02 2015.

[54] G. Krishnasamy e R. Paramesran, "Hessian semi-supervised extreme learning machine," *Neurocomputing*, vol. 207, pp. 560–567, 09 2016.

[55] M. Liu, B. Liu, C. Zhang, W. Wang e W. Sun, "Semi-supervised low rank kernel learning algorithm via extreme learning machine," *International Journal of Machine Learning and Cybernetics*, vol. 8, 06 2017.

[56] A. Mehrizi e H. sadoghi yazdi, "Semi-supervised gsom integrated with extreme learning machine," *Intelligent Data Analysis*, vol. 20, pp. 1115–1132, 09 2016.

[57] N. Zhang e S. Ding, "Unsupervised and semi-supervised extreme learning machine with wavelet kernel for high dimensional data," *Memetic Computing*, vol. 9, 06 2017.

[58] S. Ding, N. Zhang, J. Zhang, X. Xu e Z. Shi, "Unsupervised extreme learning machine with representational features," *International Journal of Machine Learning and Cybernetics*, vol. 8, 03 2015.

[59] W. Zhu, J. Miao, L. Qing e G. Huang, "Hierarchical extreme learning machine for unsupervised representation learning," *2015 International Joint Conference on Neural Networks (IJCNN)*, pp. 1–8, 2015.

[60] X. Cheng, H. Liu, X. Xu e F. Sun, "Denoising deep extreme learning machine for sparse representation," *Memetic Computing*, vol. 9, 09 2017.

[61] K. Sun, J. Zhang, C. Zhang e J. Hu, "Generalized extreme learning machine autoencoder and a new deep neural network," *Neurocomputing*, vol. 230, pp. 374–381, 2017.

[62] D. Nayak, D. Das, R. Dash, S. Majhi e B. Majhi, "Deep extreme learning machine with leaky rectified linear unit for multiclass classification of pathological brain images," *Multimedia Tools and Applications*, vol. 79, 06 2020.

[63] M. Yousefi-Azar e M. Mcdonnell, "Semi-supervised convolutional extreme learning machine," pp. 1968–1974, 05 2017.

[64] Q. She, B. Hu, Z. Luo, T. Nguyen e Y. Zhang, "A hierarchical semi-supervised extreme learning machine method for eeg recognition," *Medical amp; biological engineering amp; computing*, vol. 57, p. 147—157, January 2019.

[65] M. Xia, J. Wang, J. Liu, L. Weng e Y. Xu, "Density-based semi-supervised online sequential extreme learning machine," *Neural Comput. Appl.*, vol. 32, p. 7747–7758, jun 2020.

[66] C. Cortes e V. N. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.

[67] Y. Liu, H. T. Loh e S. B. Tor, "Comparison of extreme learning machine with support vector machine for text classification," em *Proceedings of the 18th International Conference on Innovations in Applied Artificial Intelligence*, IEA/AIE'2005, (Berlin, Heidelberg), p. 390–399, Springer-Verlag, 2005.

[68] J. Chorowski, J. Wang e J. M. Zurada, "Review and performance comparison of svm- and elm-based classifiers," *Neurocomputing*, vol. 128, pp. 507–516, 2014.

[69] H. Zhong, C. Miao, Z. Shen e Y. Feng, "Comparing the learning effectiveness of bp, elm, i-elm, and svm for corporate credit ratings," *Neurocomputing*, vol. 128, pp. 285–295, 2014.

[70] S. Qiu, J. Wang, C. Tang e D. Du, "Comparison of elm, rf, and svm on e-nose and e-tongue to trace the quality status of mandarin (citrus unshiu marc.)," *Journal of Food Engineering*, vol. 166, pp. 193–203, 12 2015.

[71] L. Zhang, D. Zhang e F. Tian, *SVM and ELM: Who Wins? Object Recognition with Deep Convolutional Features from ImageNet*, pp. 249–263. 01 2016.

[72] E. Gelenbe, "Random neural networks with negative and positive signals and product form solution," *Neural Computation*, vol. 1, no. 4, pp. 502–510, 1989.

[73] D. Broomhead e D. Lowe, "Radial basis functions, multivariable functional interpolation and adaptive networks," *ROYAL SIGNALS AND RADAR ESTABLISHMENT MALVERN (UNITED KINGDOM)*, vol. RSRE-MEMO-4148, 03 1988.

[74] M.-B. Li, G.-B. Huang, P. Saratchandran e N. Sundararajan, "Channel equalization using complex extreme learning machine with rbf kernels," pp. 114–119, 05 2006.

[75] F. Fernández-Navarro, C. Hervás-Martínez, J. Sanchez-Monedero e P. A. Gutiérrez, "Melm-grbf: A modified version of the extreme learning machine for generalized radial basis function neural networks," *Neurocomputing*, vol. 74, no. 16, pp. 2502–2510, 2011. Advances in Extreme Learning Machine: Theory and Applications Biological Inspired Systems. Computational and Ambient Intelligence.

[76] J. Hopfield, "Neural networks and physical systems with emergent collective computational abilities," *Proceedings of the National Academy of Sciences of the United States of America*, vol. 79, pp. 2554–8, 05 1982.

[77] H. Liang, H. Cheng, J. Wei, L. Zhang, L. Yang, Y. Zhao e H. Guo, "Memristive neural networks: A neuromorphic paradigm for extreme learning machine," *IEEE Transactions on Emerging Topics in Computational Intelligence*, vol. 3, pp. 15–23, 02 2019.

[78] J. Liu, X. Liu, C. Liu, B. T. Le e D. Xiao, "Random search enhancement of incremental regularized multiple hidden layers elm," *IEEE Access*, vol. 7, pp. 36866–36878, 2019.

[79] B. P. Chacko, V. R. Vimal Krishnan, G. Raju e P. Babu Anto, "Handwritten character recognition using wavelet energy and extreme learning machine," *International Journal of Machine Learning and Cybernetics*, vol. 3, p. 149–161, Sept. 2011.

[80] H.-J. Rong, Y.-X. Jia e G.-S. Zhao, "Aircraft recognition using modular extreme learning machine," *Neurocomputing*, vol. 128, p. 166–174, Mar. 2014.

[81] Z. Zhou, C. Wang, X. Gao, Z. Zhu, X. Hu, X. Zheng e L. Jiang, "Fabric defect detection and classifier via multi-scale dictionary learning and an adaptive differential evolution optimized regularization extreme learning machine," *Fibres and Textiles in Eastern Europe*, vol. 27, p. 67–77, Feb. 2019.

[82] Tian, Zhang, Chen, Geng e Wang, "Selective ensemble based on extreme learning machine for sensor-based human activity recognition," *Sensors*, vol. 19, p. 3468, Aug. 2019.

[83] N. Rodriguez, L. Barba, P. Alvarez e G. Cabrera-Guerrero, "Stationary wavelet-fourier entropy and kernel extreme learning for bearing multi-fault diagnosis," *Entropy*, vol. 21, p. 540, May 2019.

[84] Z.-T. Liu, S.-H. Li, W.-H. Cao, D.-Y. Li, M. Hao e R. Zhang, "Combining 2d gabor and local binary pattern for facial expression recognition using extreme learning machine," *Journal of Advanced Computational Intelligence and Intelligent Informatics*, vol. 23, p. 444–455, May 2019.

[85] X.-c. Yang, X.-r. Yan e C.-f. Song, "Pressure prediction of coal slurry transportation pipeline based on particle swarm optimization kernel function extreme learning machine," *Mathematical Problems in Engineering*, vol. 2015, p. 1–7, 2015.

[86] M. Zhang, X. Liu e Z. Zhang, "A soft sensor for industrial melt index prediction based on evolutionary extreme learning machine," *Chinese Journal of Chemical Engineering*, vol. 24, p. 1013–1019, Aug. 2016.

[87] W. Zou, F. Yao, B. Zhang, C. He e Z. Guan, "Verification and predicting temperature and humidity in a solar greenhouse based on convex bidirectional extreme learning machine algorithm," *Neurocomputing*, vol. 249, p. 72–85, Aug. 2017.

[88] Zhang e Wei, "A hybrid model based on principal component analysis, wavelet transform, and extreme learning machine optimized by bat algorithm for daily solar radiation forecasting," *Sustainability*, vol. 11, p. 4138, July 2019.

[89] W. Sun e M. Duan, "Analysis and forecasting of the carbon price in china's regional carbon markets based on fast ensemble empirical mode decomposition, phase space reconstruction, and an improved extreme learning machine," *Energies*, vol. 12, p. 277, Jan. 2019.

[90] A. Naz, M. Javed, N. Javaid, T. Saba, M. Alhussein e K. Aurangzeb, "Short-term electric load and price forecasting using enhanced extreme learning machine optimization in smart grids," *Energies*, vol. 12, p. 866, Mar. 2019.

[91] J. Zhang, S. Ding, N. Zhang e Z. Shi, "Incremental extreme learning machine based on deep feature embedded," *International Journal of Machine Learning and Cybernetics*, vol. 7, p. 111–120, Sept. 2015.

[92] Y. Chen, S. Song, S. Li, L. Yang e C. Wu, "Domain space transfer extreme learning machine for domain adaptation," *IEEE Transactions on Cybernetics*, vol. 49, p. 1909–1922, May 2019.

[93] G. Pei, Y. Wang, Y. Cheng e L. Zhang, "Joint label-density-margin space and extreme elastic net for label-specific features," *IEEE Access*, vol. 7, p. 112304–112317, 2019.

[94] Q. He, X. Jin, C. Du, F. Zhuang e Z. Shi, "Clustering in extreme learning machine feature space," *Neurocomputing*, vol. 128, p. 88–95, Mar. 2014.

[95] A. K. Alshamiri, A. Singh e B. R. Surampudi, "Artificial bee colony algorithm for clustering: an extreme learning approach," *Soft Computing*, vol. 20, p. 3163–3176, Apr. 2015.

[96] J. Huang, Z. L. Yu e Z. Gu, "A clustering method based on extreme learning machine," *Neurocomputing*, vol. 277, p. 108–119, Feb. 2018.

[97] L. M. Pavelski, M. R. Delgado, C. P. Almeida, R. A. Gonçalves e S. M. Venske, "Extreme learning surrogate models in multi-objective optimization based on decomposition," *Neurocomputing*, vol. 180, p. 55–67, Mar. 2016.

[98] R. Ghiasi, M. R. Ghasemi e M. Noori, "Comparative studies of metamodeling and ai-based techniques in damage detection of structures," *Advances in Engineering Software*, vol. 125, p. 101–112, Nov. 2018.

[99] X. Peng, P. Lin, T. Zhang e J. Wang, "Extreme learning machine-based classification of adhd using brain structural mri data," *PLoS ONE*, vol. 8, p. e79476, Nov. 2013.

[100] M. Termenon, M. Graña, A. Barrós-Loscertales e C. Ávila, "Extreme learning machines for feature selection and classification of cocaine dependent patients on structural mri data," *Neural Processing Letters*, vol. 38, p. 375–387, Jan. 2013.

[101] R. K. Lama, J. Gwak, J.-S. Park e S.-W. Lee, "Diagnosis of alzheimer's disease based on structural mri images using a regularized extreme learning machine and pca features," *Journal of Healthcare Engineering*, vol. 2017, p. 1–11, 2017.

[102] Y. Jiang, Z. Deng, J. Chen, H. Wu, K.-S. Choi e S. Wang, "Intelligent diagnostic methods for thyroid nodules," *Journal of Medical Imaging and Health Informatics*, vol. 7, p. 1772–1779, Dec. 2017.

[103] Z. Cai, J. Gu, J. Luo, Q. Zhang, H. Chen, Z. Pan, Y. Li e C. Li, "Evolving an optimal kernel extreme learning machine by using an enhanced grey wolf optimization strategy," *Expert Systems with Applications*, vol. 138, p. 112814, Dec. 2019.

[104] G. Vani, R. Savitha e N. Sundararajan, "Classification of abnormalities in digitized mammograms using extreme learning machine," em *2010 11th International Conference on Control Automation Robotics amp; Vision*, IEEE, Dec. 2010.

[105] E. Soria-Olivas, J. Gomez-Sanchis, J. D. Martin, J. Vila-Frances, M. Martinez, J. R. Magdalena e A. J. Serrano, "Belm: Bayesian extreme learning machine," *IEEE Transactions on Neural Networks*, vol. 22, p. 505–509, Mar. 2011.

[106] Z. Wang, M. Li, H. Wang, H. Jiang, Y. Yao, H. Zhang e J. Xin, "Breast cancer detection using extreme learning machine based on feature fusion with cnn deep features," *IEEE Access*, vol. 7, p. 105146–105158, 2019.

[107] W. Huang, Z. M. Tan, Z. Lin, G. Huang, J. Zhou, C. K. Chui, Y. Su e S. Chang, "A semi-automatic approach to the segmentation of liver parenchyma from 3d ct images with extreme learning machine," em *2012 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, IEEE, Aug. 2012.

[108] G. L. B. Ramalho, P. P. Rebouças Filho, F. N. S. d. Medeiros e P. C. Cortez, "Lung disease detection using feature extraction and extreme learning machine," *Revista Brasileira de Engenharia Biomédica*, vol. 30, p. 207–214, Sept. 2014.

[109] W. Zhu, W. Huang, Z. Lin, Y. Yang, S. Huang e J. Zhou, "Data and feature mixed ensemble based extreme learning machine for medical object detection and segmentation," *Multimedia Tools and Applications*, vol. 75, p. 2815–2837, May 2015.

[110] O. F. Alcin, F. Ucar e D. Korkmaz, "Extreme learning machine based robotic arm modeling," em *2016 21st International Conference on Methods and Models in Automation and Robotics (MMAR)*, IEEE, Aug. 2016.

[111] J. Duan, Y. Ou, J. Hu, Z. Wang, S. Jin e C. Xu, "Fast and stable learning of dynamical systems based on extreme learning machine," *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 49, p. 1175–1185, June 2019.

[112] I. Landa-Torres, E. G. Ortiz-Garcia, S. Salcedo-Sanz, M. J. Segovia-Vargas, S. Gil-Lopez, M. Miranda, J. M. Leiva-Murillo e J. Del Ser, "Evaluating the internationalization success of companies through a hybrid grouping harmony search—extreme learning machine approach," *IEEE Journal of Selected Topics in Signal Processing*, vol. 6, p. 388–398, Aug. 2012.

[113] S. Sokolov-Mladenović, M. Milovančević, I. Mladenović e M. Alizamir, "Economic growth forecasting by artificial neural network with extreme learning machine based on trade, import and export parameters," *Computers in Human Behavior*,

vol. 65, p. 43–45, Dec. 2016.
[114] L. Milačić, S. Jović, T. Vujović e J. Miljković, "Application of artificial neural network with extreme learning machine for economic growth estimation," *Physica A: Statistical Mechanics and its Applications*, vol. 465, p. 285–288, Jan. 2017.
[115] V. Marjanović, M. Milovančević e I. Mladenović, "Prediction of gdp growth rate based on carbon dioxide (co2) emissions," *Journal of CO2 Utilization*, vol. 16, p. 212–217, Dec. 2016.
[116] A. K. Shukla, S. Kumar, R. Jagdev, P. K. Muhuri e Q. M. Danish Lohani, "Interval type-2 fuzzy weighted extreme learning machine for gdp prediction," em *2018 International Joint Conference on Neural Networks (IJCNN)*, IEEE, July 2018.
[117] W. Sun, C. Wang e C. Zhang, "Factor analysis and forecasting of co2 emissions in hebei, using extreme learning machine based on particle swarm optimization," *Journal of Cleaner Production*, vol. 162, p. 1095–1101, Sept. 2017.
[118] R. Wang, C.-Y. Chow, Y. Lyu, V. C. S. Lee, S. Kwong, Y. Li e J. Zeng, "Taxirec: Recommending road clusters to taxi drivers using ranking-based extreme learning machines," *IEEE Transactions on Knowledge and Data Engineering*, vol. 30, p. 585–598, Mar. 2018.
[119] Z.-L. Sun, K. M. Ng, J. Soszynska-Budny e M. S. Habibullah, "Application of the lp-elm model on transportation system lifetime optimization," *IEEE Transactions on Intelligent Transportation Systems*, vol. 12, p. 1484–1494, Dec. 2011.
[120] Y.-m. Xing, X.-j. Ban e R. Liu, "A short-term traffic flow prediction method based on kernel extreme learning machine," em *2018 IEEE International Conference on Big Data and Smart Computing (BigComp)*, IEEE, Jan. 2018.
[121] Z. Geng, J. Dong, J. Chen e Y. Han, "A new self-organizing extreme learning machine soft sensor model and its applications in complicated chemical processes," *Engineering Applications of Artificial Intelligence*, vol. 62, p. 38–50, June 2017.
[122] Z.-H. You, M. Zhou, X. Luo e S. Li, "Highly efficient framework for predicting interactions between proteins," *IEEE Transactions on Cybernetics*, vol. 47, p. 731–743, Mar. 2017.
[123] Y. Jiang, A. Bi, K. Xia, J. Xue e P. Qian, "Exemplar-based data stream clustering toward internet of things," *The Journal of Supercomputing*, vol. 76, p. 2929–2957, Nov. 2019.
[124] D. Zheng, Z. Hong, N. Wang e P. Chen, "An improved lda-based elm classification for intrusion detection algorithm in iot application," *Sensors*, vol. 20, p. 1706, Mar. 2020.
[125] F. Huang, K. Yin, J. Huang, L. Gui e P. Wang, "Landslide susceptibility mapping based on self-organizing-map network and extreme learning machine," *Engineering Geology*, vol. 223, p. 11–22, June 2017.
[126] W. Li, C. Chen, H. Su e Q. Du, "Local binary patterns and extreme learning machine for hyperspectral imagery classification," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 53, p. 3681–3693, July 2015.
[127] M. Guo, Y. Ma, X. Yang e R. W. Mankin, "Detection of damaged wheat kernels using an impact acoustic signal processing technique based on gaussian modelling and an improved extreme learning machine algorithm," *Biosystems Engineering*, vol. 184, p. 37–44, Aug. 2019.
[128] W. Schmidt, M. Kraaijveld e R. Duin, "Feedforward neural networks with random weights," em *Proceedings., 11th IAPR International Conference on Pattern Recognition. Vol.II. Conference B: Pattern Recognition Methodology and Systems*, IEEE Comput. Soc. Press.
[129] Y.-H. Pao, G.-H. Park e D. J. Sobajic, "Learning and generalization characteristics of the random vector functional-link net," *Neurocomputing*, vol. 6, p. 163–180, Apr. 1994.
[130] S. Chen e D. Tan, "A sa-ann-based modeling method for human cognition mechanism and the psaco cognition algorithm," *Complexity*, vol. 2018, p. 1–21, Jan. 2018.